

СТРАТЕГИИ ОПТИМИЗАЦИИ И МЕТОДЫ ОЦЕНКИ ДЛЯ ТОЧНОЙ НАСТРОЙКИ БОЛЬШИХ ЯЗЫКОВЫХ МОДЕЛЕЙ

В.В. Денисенко, доцент

Л.С. Чесников, студент

**Воронежский государственный университет инженерных технологий
(Россия, г. Воронеж)**

DOI:10.24412/2500-1000-2024-4-1-180-184

Аннотация. В данной статье представлен обзор стратегий оптимизации и методов оценки эффективности дообучения больших языковых моделей. Рассмотрены ключевые аспекты выбора функции потерь, оптимизатора и настройки скорости обучения, а также методы оценки эффективности дообучения, включая сравнительные эксперименты и специальные техники анализа. Приведены выводы о значимости дообучения для развития области NLP и его будущих направлениях.

Ключевые слова: дообучение, языковые модели, оптимизация, оценка эффективности, функция потерь, оптимизатор, скорость обучения, переобучение, анализ чувствительности, кросс-валидация.

В современном мире обработка естественного языка (NLP) играет ключевую роль во многих областях, включая медицину, финансы, образование и многие другие. Одной из наиболее перспективных технологий в этой области являются большие языковые модели (LLM), основанные на трансформерах. Эти модели способны обучаться на огромных объемах данных и демонстрировать впечатляющие результаты в различных NLP-задачах. Однако, несмотря на свои возможности, LLM часто требуют дополнительной настройки для достижения оптимальных результатов в конкретных задачах и доменных областях. Этот процесс называется дообучением. Дообучение включает в себя адаптацию модели к специфическим требованиям и данным, улучшение ее производительности и точности.

Результаты исследования

Основные концепции, лежащие в основе современных языковых моделей, включают в себя такие известные модели, как GPT и BERT, а также их архитектурные особенности.

GPT, или Generative Pre-trained Transformer, является одной из самых мощных и широко известных языковых моделей. Она использует архитектуру трансформера, которая состоит из нескольких слоев многоголового внимания.

Это позволяет модели обучаться на больших объемах текстовых данных и генерировать последовательности текста, которые кажутся созданными человеком [1].

BERT, или Bidirectional Encoder Representations from Transformers, также использует архитектуру трансформера, но отличается тем, что обучается на текстах, где каждое слово имеет контекст в обоих направлениях. Это позволяет модели лучше понимать семантику предложений и контекст слов.

Оба этих подхода обучаются на больших объемах текстовых данных, используя технику, известную как предварительное обучение. Предварительное обучение включает в себя обучение модели на большом корпусе текстовых данных без каких-либо специальных меток или задач. Это позволяет модели учиться общему пониманию языка и его структуры [2]. После этого модель может быть дополнительно обучена или адаптирована для выполнения конкретных задач, что и называется дообучением.

Существует несколько причин, по которым большие языковые модели могут нуждаться в дообучении:

1. Улучшение производительности на специфических задачах: Большие языковые модели, такие как GPT-3 и BERT, обладают широкими возможностями и могут ис-

пользоваться для множества различных задач обработки естественного языка. Однако они не всегда оптимизированы для конкретной задачи. Дообучение позволяет адаптировать модель к конкретной задаче, улучшая ее производительность.

2. Уменьшение эффекта переноса знаний (knowledge transfer): При обучении большой языковой модели на больших объемах данных, она может усваивать общие знания и шаблоны, которые не всегда применимы к конкретной задаче. Дообучение помогает уменьшить этот эффект, фокусируя модель на специфических знаниях и задачах.

3. Адаптация к новым доменам: Большие языковые модели обычно обучаются на общих корпусах текстовых данных. Однако некоторые задачи требуют специализации в определенных доменных областях, таких как медицина, право или финансы. Дообучение позволяет адаптировать модель к новому домену, предоставляя ей данные и задачи из этой области.

Существует несколько методов дообучения имеющих свои преимущества и недостатки [3].

Прямое дообучение (Direct Fine-Tuning) – это метод, который предполагает непосредственное дообучение всей модели на целевых данных. Он используется, когда есть достаточное количество данных для обучения и адаптации модели к конкретной задаче. Процесс прямого дообучения начинается с предварительно обученной модели, которая уже была обучена на большом объеме данных. Затем эта модель дообучается на новых данных, которые соответствуют конкретной задаче или домену. Во время этого процесса веса и параметры модели корректируются таким образом, чтобы она лучше соответствовала новым данным. Прямое дообучение может быть эффективным методом, если доступны достаточные данные для обучения и адаптации модели. Однако он может привести к переобучению, если данных слишком много или они слишком специфичны. Поэтому важно тщательно выбирать и обрабатывать данные для дообучения. Преимуществами прямого дообучения являются его простота и возможность быстро-

го получения адаптированной модели [4]. Однако он требует большого количества данных и может быть менее эффективным, чем другие методы дообучения, если данные ограничены или неоднородны.

Метод прогрессивного нарастания (Progressive Growing) представляет собой подход к дообучению который заключается в постепенном добавлении слоев в модель во время процесса обучения. Основная идея этого метода заключается в том, чтобы обеспечить плавную адаптацию модели к новым данным и задачам. Процесс прогрессивного нарастания начинается с базовой модели, которая уже была предварительно обучена на большом объеме данных. Затем добавляются дополнительные слои к этой модели, начиная с небольшого числа слоев и постепенно увеличивая их количество. Каждый новый слой обучается на основе предыдущих слоев и новых данных, что позволяет модели постепенно адаптироваться к новым задачам и данным. Этот метод особенно полезен, когда доступно ограниченное количество данных для дообучения, поскольку он позволяет модели начать обучение с меньшего количества слоев и постепенно увеличивать их количество, минимизируя риск переобучения. Кроме того, прогрессивное нарастание может улучшить общую производительность модели, позволяя ей лучше адаптироваться к новым данным и задачам. Однако стоит отметить, что метод прогрессивного нарастания может быть более сложным и трудоемким, чем прямое дообучение, поскольку он требует тщательного контроля за процессом добавления новых слоев и балансировки между скоростью обучения и качеством модели.

Метод дообучения, известный как многозадачное обучение (Multi-Task Learning), предполагает обучение модели на нескольких задачах одновременно. Основная идея этого подхода заключается в том, что обучение на нескольких задачах одновременно может улучшить обобщающую способность модели, поскольку она будет способна извлекать общие знания из различных задач. В процессе многозадачного обучения модель обучается на нескольких наборах данных, каждый из которых соот-

ветствует своей задаче. Например, модель может обучаться на данных для задач классификации текста, распознавания речи и перевода [5]. При этом модель обучается таким образом, чтобы все задачи решались одновременно. Важно отметить, что в многозадачном обучении каждая задача имеет свою собственную метрику успеха, и модель должна быть оптимизирована для всех этих метрик одновременно. Это достигается путем введения дополнительных параметров в модель, которые позволяют ей учитывать различия между задачами. Преимуществами многозадачного обучения являются улучшенная обобщающая способность модели и возможность использования ограниченных данных для обучения. Однако этот метод может быть сложным в реализации и требует тщательной настройки для достижения наилучших результатов.

Метод промежуточного дообучения (Intermediate Fine-Tuning) представляет собой подход к дообучению, который включает дообучение модели на дополнительном наборе данных, который близок к целевой задаче, перед непосредственным дообучением. Этот метод начинается с предварительно обученной модели, которая затем дообучается на промежуточном наборе данных, который может быть получен из той же доменной области, что и целевая задача, но не обязательно точно соответствовать ей. Целью этого этапа является улучшение способности модели адаптироваться к целевой задаче. Затем, после промежуточного дообучения, модель дообучается непосредственно на целевом наборе данных. Этот двухэтапный подход позволяет модели лучше адаптироваться к целевой задаче, используя преимущества промежуточного набора данных для улучшения обобщающей способности модели. Преимуществами промежуточного дообучения являются улучшенная адаптация модели к целевой задаче и возможность использования данных, которые могут быть доступны, но не идеально соответствуют целевой задаче. Однако этот метод требует дополнительного набора данных и может быть более сложным в реализации, чем прямое дообучение.

Метод дообучения, известный как адаптеры (Adapters), предполагает добавление небольших модулей к существующей языковой модели, которые обучаются на целевой задаче, при этом основные веса модели остаются фиксированными. Адаптеры представляют собой небольшие нейронные сети, которые обучаются на целевых данных, сохраняя при этом основные веса исходной модели неизменными. Это позволяет использовать преимущества предварительно обученной модели, сохраняя при этом возможность адаптации к новой задаче. Процесс дообучения с использованием адаптеров начинается с предварительно обученной модели, которая затем дополняется адаптерами. Адаптеры обучаются на целевых данных, в то время как веса основной модели остаются фиксированными. Это позволяет сохранить знания, накопленные в исходной модели, и адаптировать ее к новой задаче. Преимуществами использования адаптеров являются сохранение эффективности предварительно обученной модели и возможность быстрой адаптации к новым задачам. Однако этот метод требует дополнительного обучения адаптеров, что может потребовать дополнительных вычислительных ресурсов.

Стоит отметить важность чистки данных для проведения успешного дообучения. Также необходимо провести их предварительную обработку и форматирование. Чистые и хорошо структурированные данные играют ключевую роль в обеспечении точности и надежности модели. Чистка данных включает удаление дубликатов, неправильно формализованных записей, пропущенных или неполных значений. Это помогает уменьшить шум в данных и улучшить качество обучающего набора. Предварительная обработка данных включает преобразование данных в формат, подходящий для обучения модели. Это может включать нормализацию данных, кодирование категориальных переменных, создание новых признаков на основе существующих и т.д. Форматирование данных также важно для успешного дообучения. Данные должны быть представлены в формате, который модель мо-

жет легко понять и обработать. Например, текст должен быть преобразован в числовой формат для моделей, работающих с числами. Так же применяются методы аугментации данных для увеличения разнообразия обучающих примеров. Они помогают модели лучше справляться с новыми ситуациями и данными, которые отличаются от тех, что были использованы при обучении. Некоторые из методов аугментации включают вращение изображений, изменение яркости и контраста, добавление шума и т.д. В целом, чистка, предварительная обработка и форматирование данных являются критически важными этапами подготовки данных для дообучения. Они помогают улучшить качество данных и обеспечивают более точную и надежную работу модели.

Стратегии оптимизации также играют ключевую роль в процессе дообучения больших языковых моделей. Выбор правильной функции потерь, оптимизатора и настройка скорости обучения могут существенно повлиять на производительность модели. Выбор функции потерь зависит от конкретной задачи и типа модели. Например, для задач классификации обычно используется функция потерь кросс-энтропии, а для задач регрессии - средне-квадратическая ошибка. Важно выбрать функцию потерь, которая соответствует поставленной задаче и учитывает особенности данных. Оптимизатор отвечает за обновление весов модели в процессе обучения. Различные оптимизаторы имеют разные характеристики и подходят для разных типов задач. Настройка скорости обучения (learning rate) – это еще один важный аспект оптимизации. Слишком высокая скорость обучения может привести к переобучению, а слишком низкая – к недообучению. Настройка скорости обучения требует экспериментирования и может зависеть от конкретной задачи и модели. Регуляризация – это техника, которая помогает предотвратить переобучение. Она включает в себя добавление дополнительных ограничений в модель, чтобы уменьшить ее способность к запоминанию деталей обучающего набора данных. Например, L2-регуляризация добавляет

штраф за размер весов модели, что помогает контролировать переобучение.

Для оценки эффективности проведенного дообучения больших языковых моделей используются различные методы. Один из основных подходов – это проведение сравнительных экспериментов, в ходе которых сравнивается производительность модели до и после дообучения. Для этого обычно используются те же самые метрики, которые использовались при предварительном обучении модели. Другой подход – это тестирование моделей в разных условиях. Это может включать в себя тестирование на разных наборах данных, на разных размерах данных, на разных уровнях шума и т.д.

Важно отметить, что оценка эффективности дообучения – это непрерывный процесс. Модель может работать хорошо на одном наборе данных, но плохо на другом. Поэтому важно проводить регулярные проверки и корректировки модели, чтобы обеспечить ее оптимальную работу в различных условиях.

В заключении можно сделать следующие выводы:

- Дообучение больших языковых моделей играет ключевую роль в развитии области NLP, позволяя адаптировать модели к конкретным задачам и доменам.

- Существуют различные методы дообучения, включая перенос обучения, дообучение, настройку гиперпараметров и использование аннотаций. Каждый из них имеет свои преимущества и недостатки, и выбор метода зависит от конкретной задачи и доступных данных.

- Проблемы, связанные с дообучением, включают переобучение и недообучение, а также вопросы этики и безопасности. Необходимо разрабатывать стратегии для решения этих проблем и улучшения качества дообучения.

- Будущее дообучения связано с развитием новых подходов и технологий, которые могут улучшить эффективность и точность дообучения. Возможные приложения этих методов включают различные отрасли, такие как медицина, финансы, образование и др.

Библиографический список

1. Решение задач информационной безопасности с использованием искусственного интеллекта / А.В. Скрыпников, В.В. Денисенко, Е.Г. Хитров [и др.] // Современные наукоемкие технологии. – 2021. – № 6-2. – С. 277-281. – DOI 10.17513/snt.38734. – EDN LMFNLR.
2. Недогарок, В.В. Применение искусственного интеллекта для обработки данных / В.В. Недогарок // WORLD SCIENCE: PROBLEMS AND INNOVATIONS: сборник статей LIX Международной научно-практической конференции, Пенза, 30 ноября 2021 года. – Пенза: Наука и Просвещение (ИП Гуляев Г.Ю.), 2021. – С. 70-72. – EDN NPAХСС.
3. Врезубова, Н.А. Технологии искусственного интеллекта в процессах обработки информации / Н.А. Врезубова, Н.В. Петракова, М.А. Петраков // Современная наука: актуальные проблемы теории и практики. Серия: Естественные и технические науки. – 2023. – № 9-2. – С. 58-62. – DOI 10.37882/2223-2982.2023.9-2.05. – EDN LTDUPS.
4. Шотыло Д.М., Крайнова В.Е., Скурыдин А.В. Тенденции развития искусственных нейронных сетей в цифровой экономике // ЭКОНОМИНФО. – 2018. – №4. – С. 65-69.
5. Распознавание рукописного текста с использованием нейронных сетей / А.В. Скрыпников, В.В. Денисенко, Е.Г. Хитров [и др.] // Современные наукоемкие технологии. – 2021. – № 6-1. – С. 91-95. – DOI 10.17513/snt.38703. – EDN EZVXSБ.

**OPTIMIZATION STRATEGIES AND EVALUATION METHODS FOR FINE-TUNING
LARGE LANGUAGE MODELS**

V.V. Denisenko, *Associate Professor*

L.S. Chesnikov, *Student*

Voronezh State University of Engineering Technologies
(Russia, Voronezh)

Abstract. *This paper provides a comprehensive review of optimization strategies and evaluation methods for fine-tuning large language models. Key aspects such as the selection of loss function, optimizer, and learning rate tuning are discussed, along with evaluation methods including comparative experiments and specialized analysis techniques. Conclusions are drawn regarding the significance of fine-tuning in the development of NLP and its future directions.*

Keywords: *fine-tuning, language models, optimization, evaluation, loss function, optimizer, learning rate, overfitting, sensitivity analysis, cross-validation.*